深度学习与自然语言处理第二次作业

EM 算法估计高斯混合模型参数

惠仪

SY2202328@buaa.edu.cn

摘要

使用链接中的代码身高数据，使用 EM 算法来估计高斯混合模型的参数，并使用这些参数来进行预测。

1 理论方法

1.1 高斯混合模型

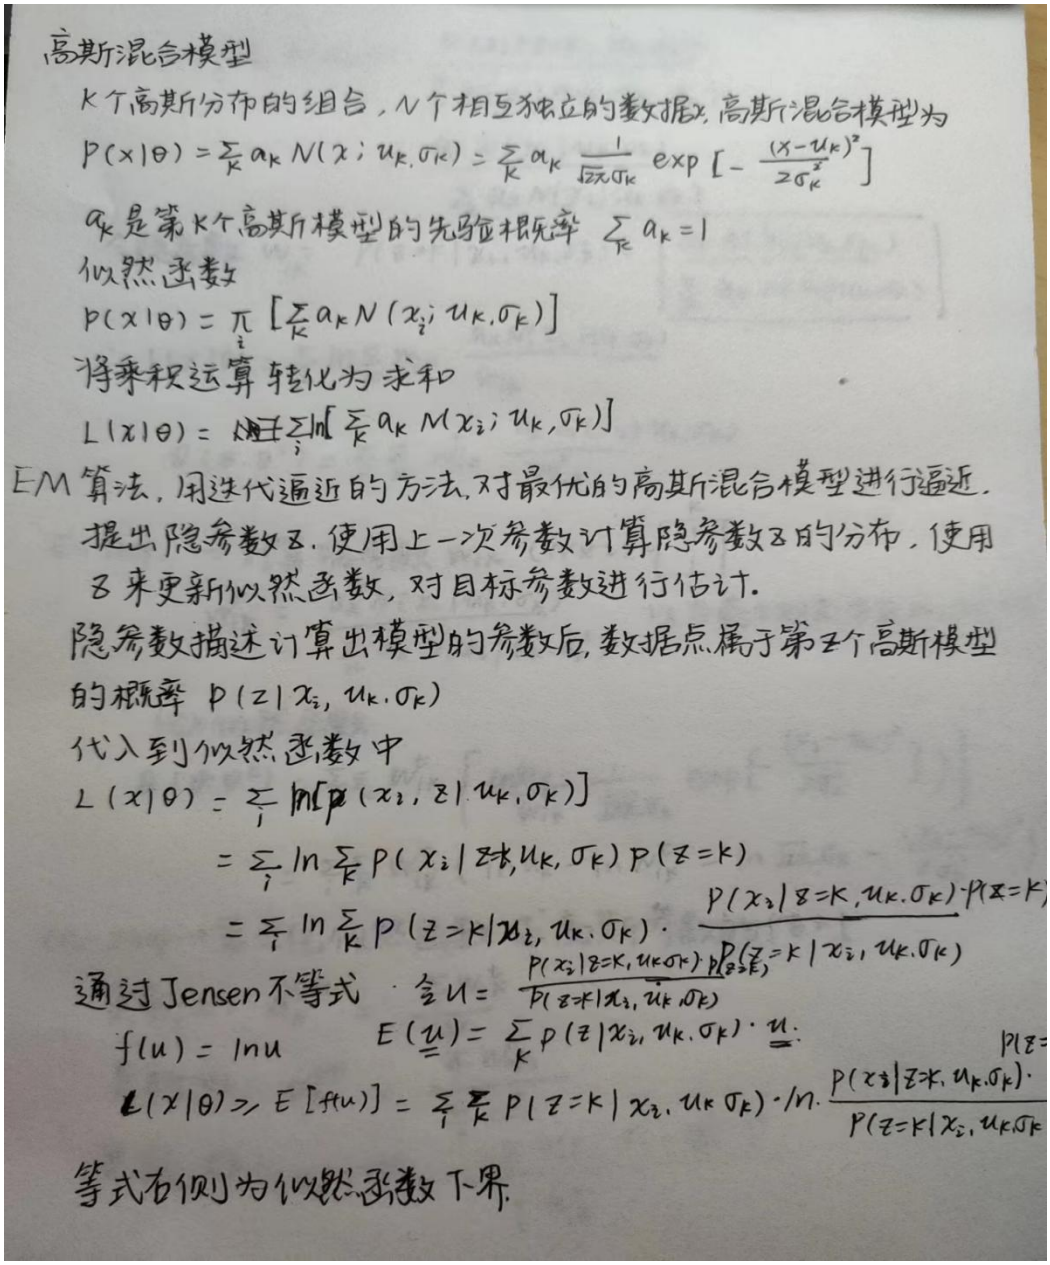

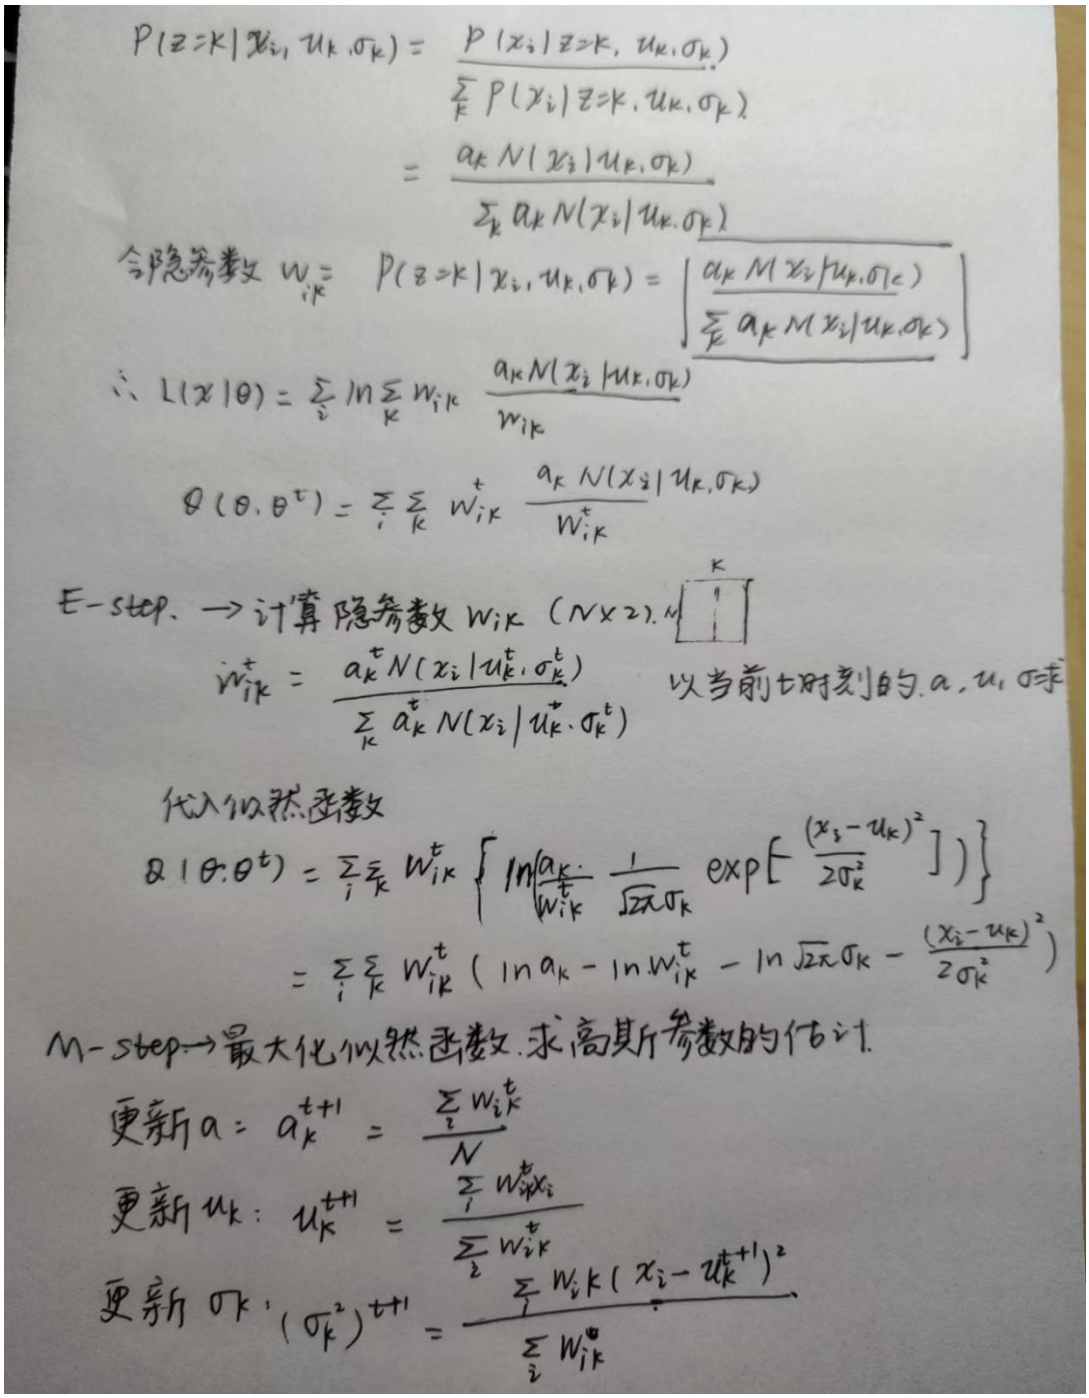

2 实验及分析

2.1 数据

数据集包含了 2000 个互相独立的数据 x，分布直方图有 2 个峰，可以得出是 2 个高斯分布的组合，K=2，绘制的直方图如图所示。

```python
np.random.seed(1)
# 定义高斯分布的参数
mean1, std1 = 164, 3
mean2, std2 = 176, 5

# 从两个高斯分布中生成样本
data1 = np.random.normal(mean1, std1, 500)
data2 = np.random.normal(mean2, std2, 1500)
data = np.concatenate((data1, data2), axis=0)
```

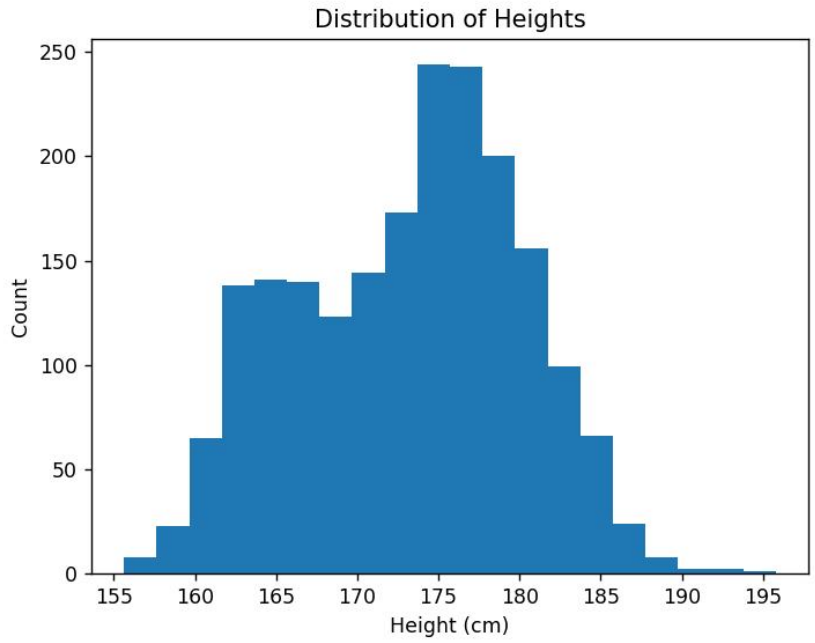

2.2 算法

首先初始化模型参数，包括 a、均值、协方差矩阵。

```python
def em(Y,K,iter):
    X = Y
    #初始化参数,a、均值、协方差
    N, D = X.shape
    a = np.ones((K, 1)) / K
    mu = np.array([X[np.random.choice(N)] for _ in range(K)])#两组数据中，Y[i]从2000个数随机选一个数分别作为均值
    cov =np.array([np.eye(D) for _ in range(K)])#两个（2，1，1）协方差阵，各个向量的协方差
    w = np.zeros((N, K))#(2000,2)零阵，两列对应两个k
```

E-step 根据理论公式求隐变量 w。

```
for i in range(iter):
    #E-step.求隐变量wik,概率
    p = np.zeros((N, K))
    for k in range(K):
        p[:,k]=a[k]*gauss(X,mu[k],cov[k])
    psum=np.sum(p,axis=1)#将矩阵压缩为1列
    w=p / psum[:, None]
```

M-Step，根据公式表示求解参数。

```
#M-setp,更新参数a、miu、cov
sumw = np.sum(w, axis=0)
#更新a,每一类的占比
a = sumw / N
#针对每一类，根据公式形式
for k in range(K):
    #求均值miu，先求wx的乘积
    w_X = np.multiply(X, w[:, [k]])
    mu[k] = np.sum(w_X, axis=0) / sumw[k]
    #求cov，先求x-mu，再求w*
    X_mu_k = np.subtract(X, mu[k])
    w_X_mu_k = np.multiply(w[:, [k]], X_mu_k)
    #np.transpose矩阵转置，dot矩阵乘法
    cov[k] = np.dot(np.transpose(w_X_mu_k), X_mu_k) / sumw[k]
```

最后打印出结果。

```
D:\anaconda3-4.3.0\envs\pytorch\python.exe D:/postgr
初始两类的均值分别为: 0.25 0.75
预测均值为: 0.2517236476884116 0.7482763523115893
初始均值为: 164 176
预测均值为: [164.1481504] [176.16306431]
初始方差为: 9 25
预测方差为: [[8.77420697]] [[25.19340661]]

Process finished with exit code 0
```

由计算结果可以看出，经过多次迭代后，模型的参数与实际参数的误差很小。生成散点图。

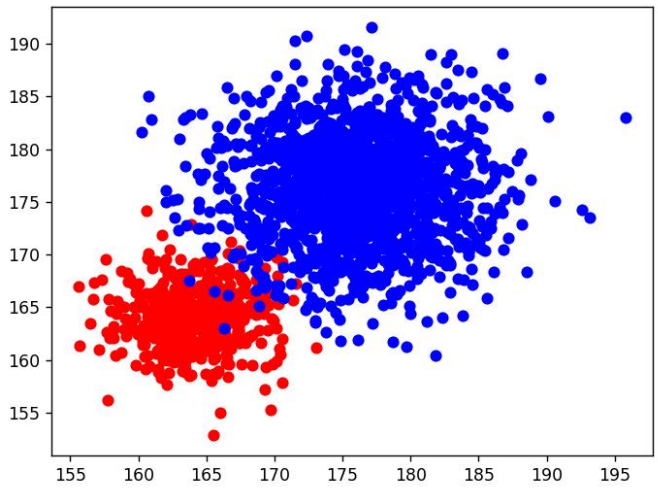

3 参考文献

[1] https://zhuanlan.zhihu.com/p/326055752